Онлайн ритейл. Анализ пользователей и их заказов.

Медведев П.А., Октысюк К.Д.

МГУ им. М.В. Ломоносова

29 апреля 2026

Цели и структура исследования

Задача исследования – определить основные категории клиентов сервиса и построить модель регрессии для количества товара в заказе.

План исследования

1. EDA
   - Анализ покупателей и заказов
   - Анализ выручки
   - Анализ оценок
2. Задача кластеризации пользователей
3. Задача регрессии

Описание данных

- **customer_id** – идентификатор пользователя
- **order_date** – дата заказа
- **product_id** – идентификатор товара
- **category_id** – идентифактор категории товара
- **category_name** – название категории товара
- **product_name** – количество баллов собственности
- **quantity** – количество заказанного товара
- **price** – цена за единицу товара
- **payment_method** – способ оплаты
- **city** – город
- **review_score** – оценка товара
- **gender** – пол
- **age** – возраст

Анализ клиентов и заказов

Демографические признаки

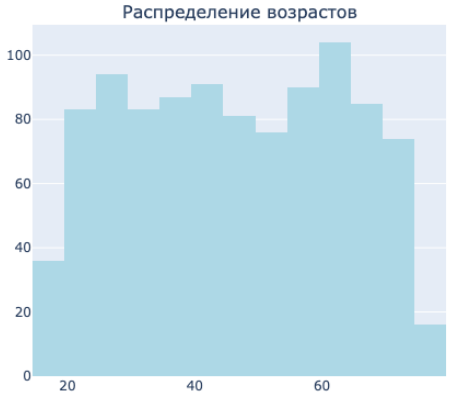

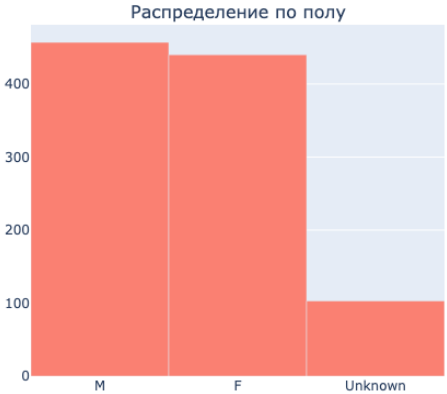

Анализ клиентов и заказов

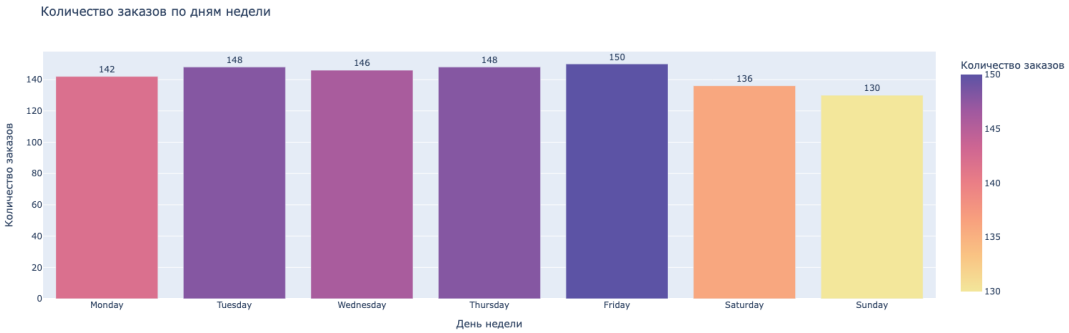

Анализ клиентов и заказов

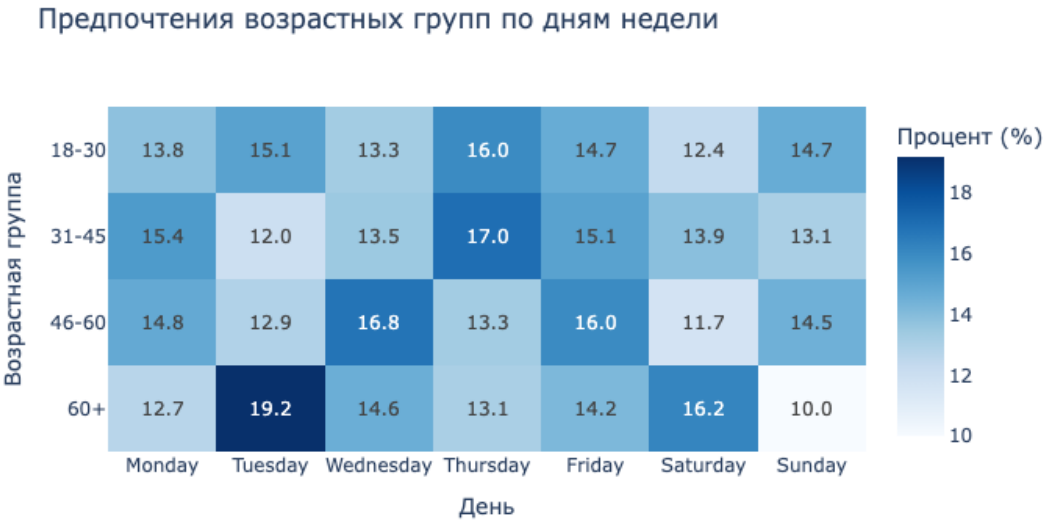

Анализ клиентов и заказов

Анализ выручки

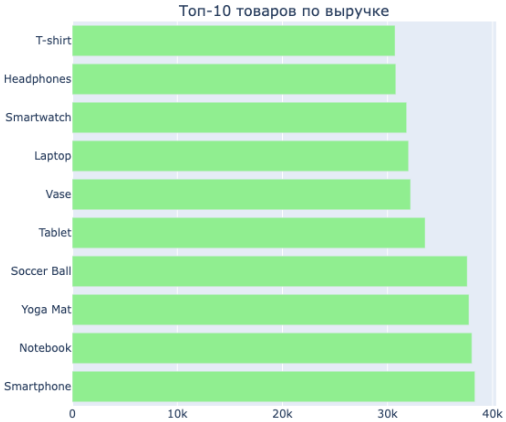

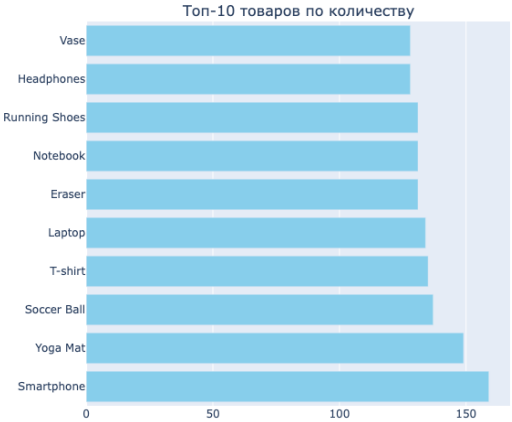

Анализ выручки

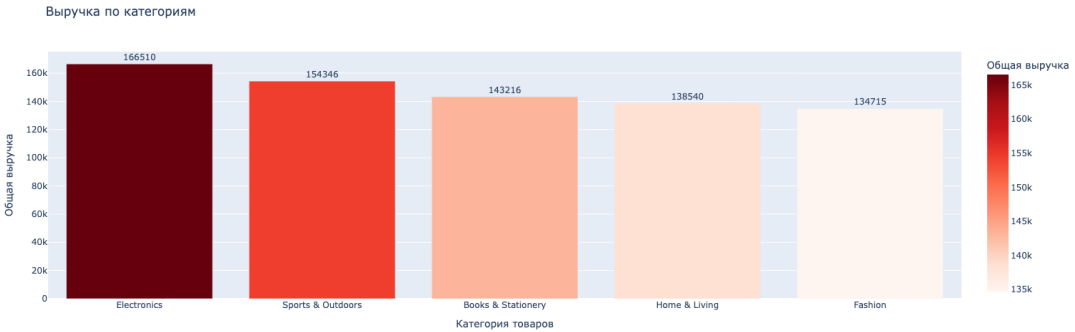

Анализ выручки

Анализ выручки

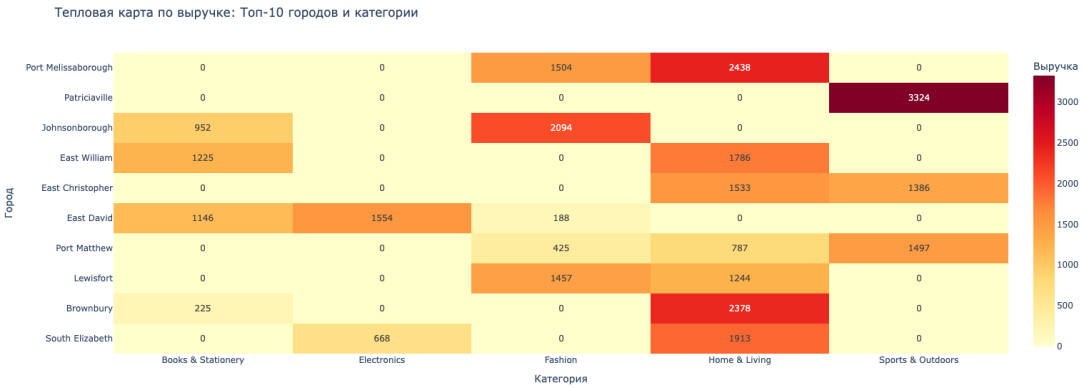

Анализ выручки

Распределение выручки

Анализ выручки

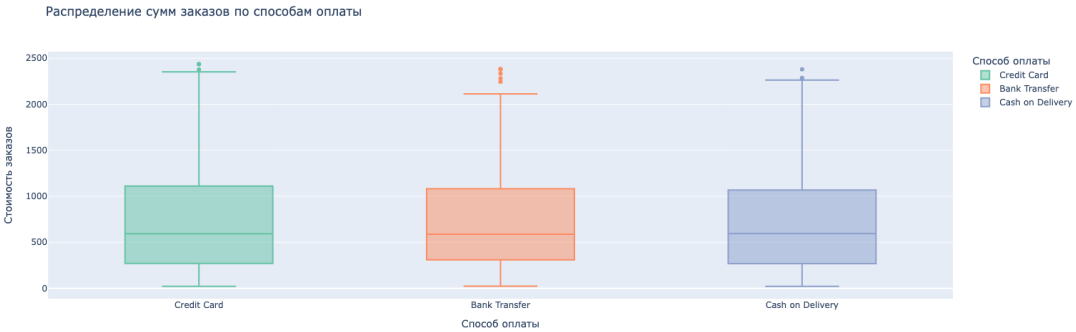

Анализ выручки

Анализ способов оплаты

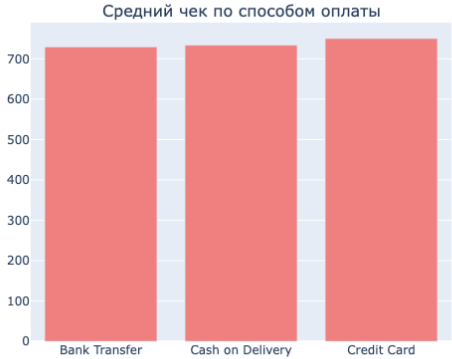

Анализ оценок

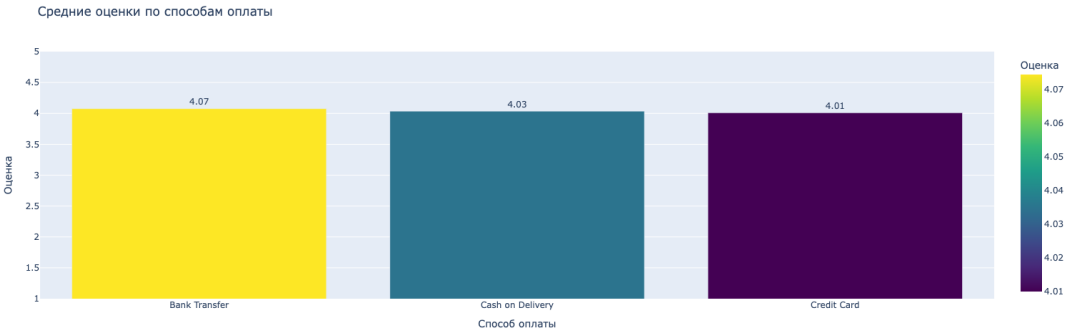

Анализ оценок

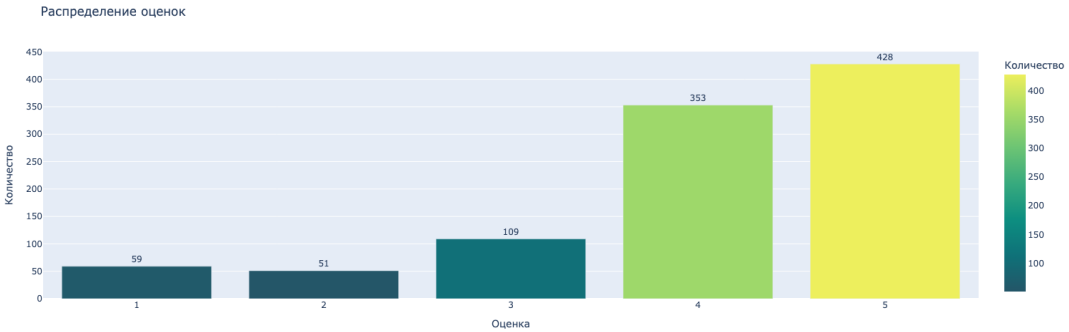

Анализ оценок

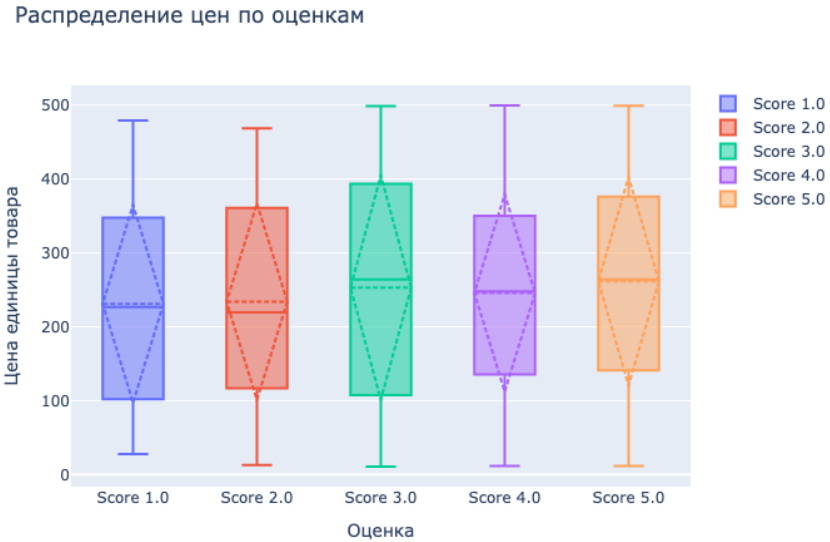

Анализ оценок

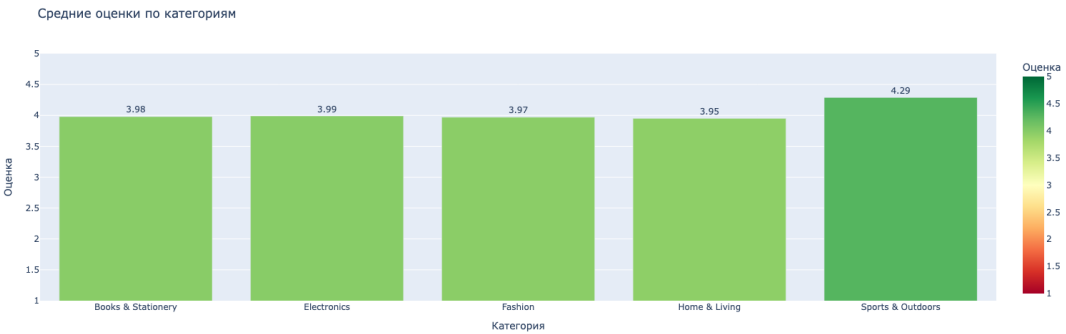

Анализ оценок

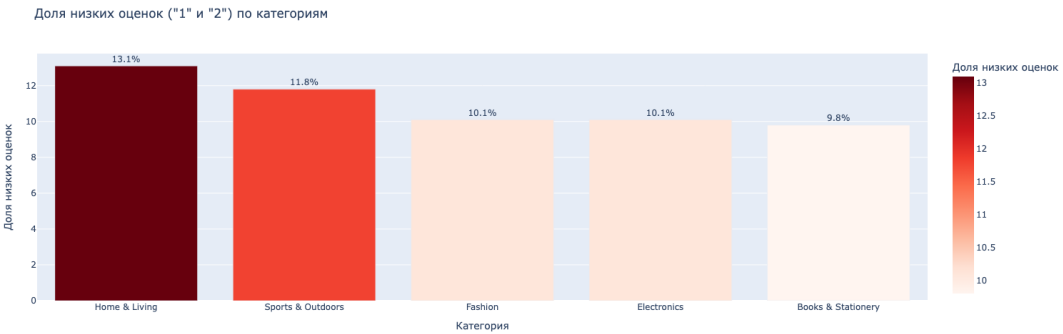

Модель регрессии для количества товара

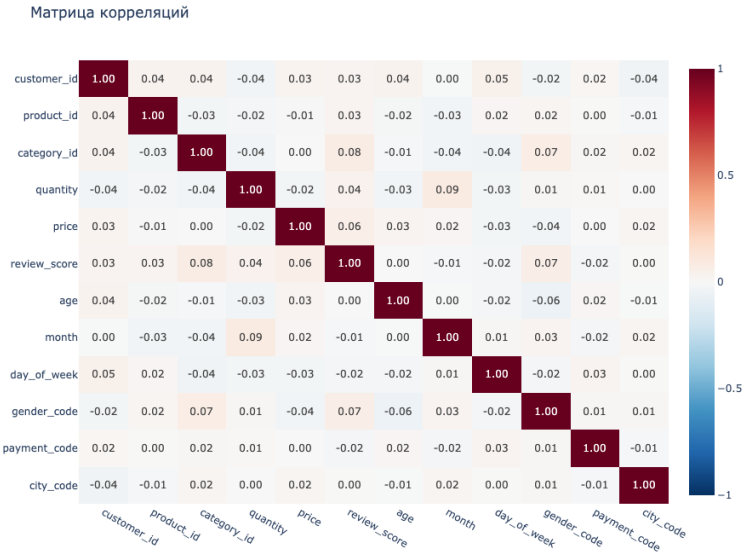

Модель регрессии для количества товара

Замечание

По приведенному выше графику видно, что корреляция между различными признаками очень мала. Максимальное значение, равное 0.09, достигается на признаках month и quantity. Отсюда можно сделать вывод, что на данном датасете не получится построить точную модель.

Модель регрессии для количества товара

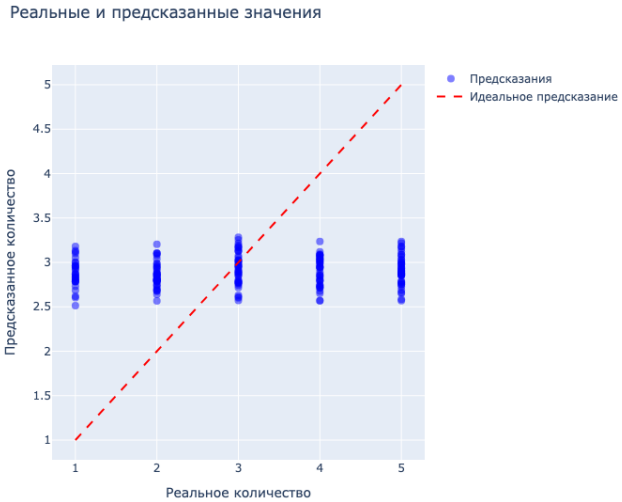

Модель регрессии для количества товара

Вывод

- Как и предполагалось на этапе анализа матрицы корреляции, модель получилась слабая
- На обучающей выборке $R^2 = 0.0142$, на тестовой $R^2 = -0.0248$
- Приведем метрики ошибок на тестовой выборке:
  $\text{MAE} = 1.19, \ \text{RMSE} = 1.39, \ \text{MAPE} = 51.11\%$

Кластеризация

Кластеризация пользователей проведена по следующим признакам:

1. По полу, возрасту и месяцу покупки
2. По полу, возрасту и общей цене заказа
3. По полу, возрасту и оценке

Так как мы работаем с небольшим (1000 строк) датасетом, кластеризация проводится с помощью иерархического алгоритма. В качестве метрики выбран коэффициент силуэта.

Кластеризация по полу, возрасту и месяцу покупки

Лучшие параметры:

- Количество кластеров: 10
- Метод linkage: average
- Silhouette Score: 0.3278

Кластеризация по полу, возрасту и месяцу покупки

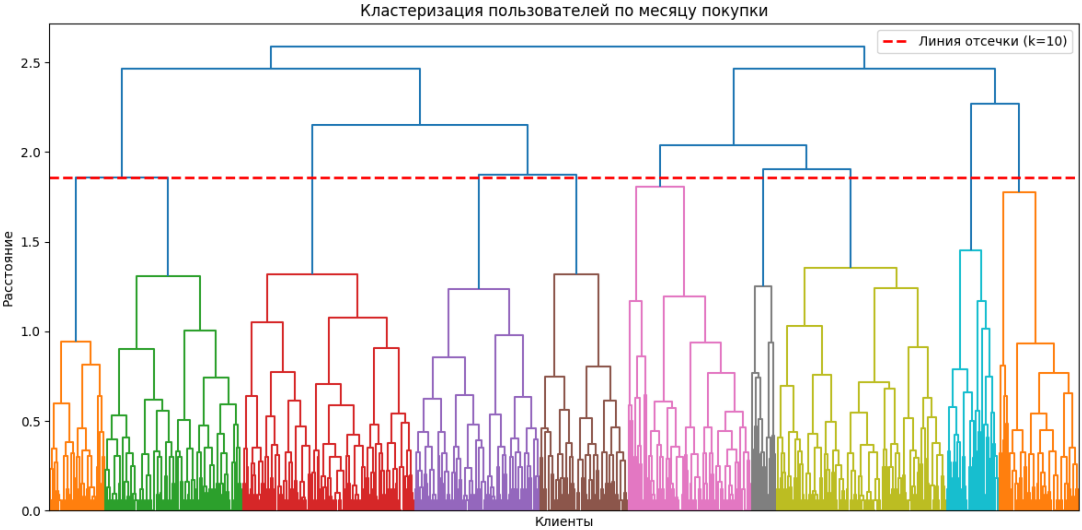

Кластеризация по полу, возрасту и сумме заказа

Лучшие параметры:

- Количество кластеров: 10
- Метод linkage: ward
- Silhouette Score: 0.3578

Кластеризация по полу, возрасту и сумме заказа

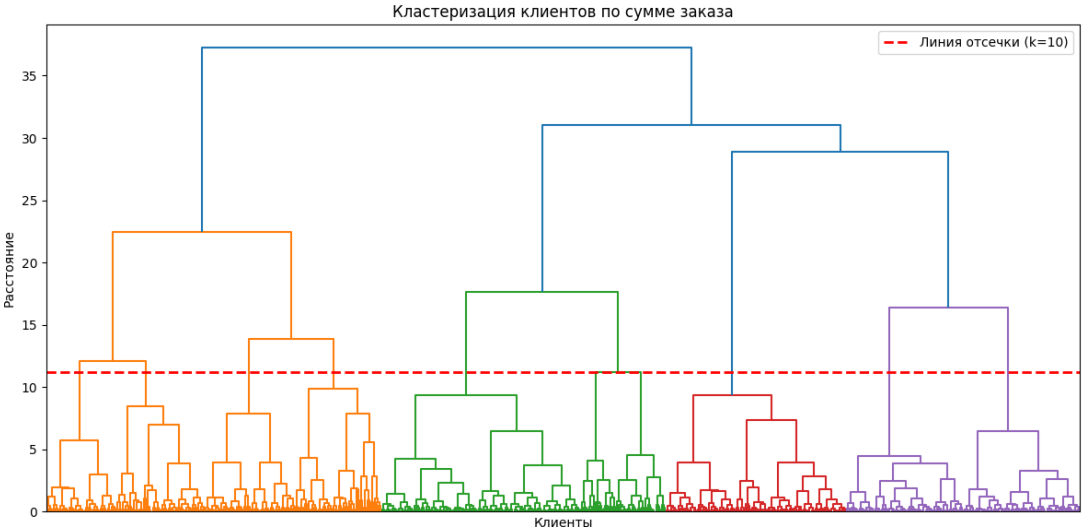

По полу, возрасту и оценке

Лучшие параметры:

- Количество кластеров: 10
- Метод linkage: average
- Silhouette Score: 0.3901
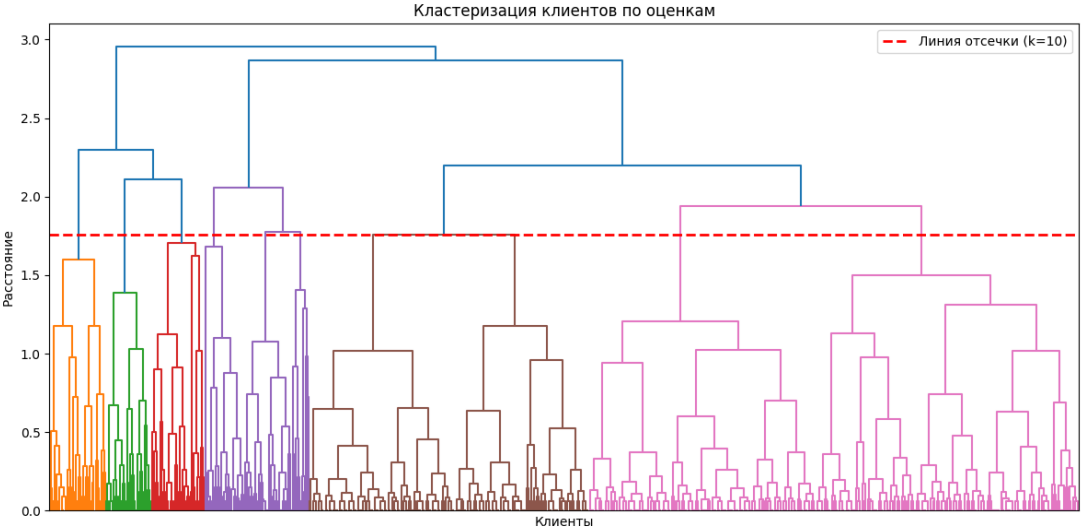
По полу, возрасту и оценке